

Poročilo za izpitni seminar: Implementacija vmesnika možgani-računalnik za klasifikacijo med dvema motoričnima aktivnostma.

30.1.2024

Jakob Dekleva

Univerza v Ljubljani, Fakulteta za računalništvo in informatiko

1 Uvod

Za temo našega izpitnega seminarja smo izbrali implementacijo možgansko-računalniškega vmesnika, namenjenega klasifikaciji med dvema vrstama motoričnih aktivnosti. Osredotočili smo se na analizo in obdelavo EEG podatkov, izbranih iz baze EEGMMI DS[1], s poudarkom na posnetku z imaginarno motorično aktivnostjo, označenim kot S001. V poročilu podrobno opisujemo našo specifično implementacijo metod za klasifikacijo in navajamo povezave na predavanja iz predmeta Komunikacija človek-računalnik. V poglavju o rezultatih predstavljamo dosežke naše klasifikacije, medtem ko v razdelku diskusije obravnavamo možne izboljšave programa. Naš pristop temelji na uporabi metode skupnih prostorskih vzorcev, ki omogoča ekstrakcijo relevantnih značilk iz EEG signalov. Dodatno smo za generacijo značilk uporabili pasovno prepustni filter in linearno diskriminantno analizo, ki je bila ključna za klasifikacijo posameznih značilk.

2 Metode

Naš projekt smo začeli z izvozom signala v naš program, pri čemer smo uporabili knjižnico WFDB (WaveForm DataBase) Toolbox [2], ki vključuje funkcijo `rdsamp`. S pomočjo te funkcije smo izvozili signale subjekta S001. Nadaljevali smo z izvozom intervalov, za kar smo implementirali funkcijo iz laboratorijskih vaj `getIntervals`. Ta funkcija razčlenjuje anotacije, shranjene skupaj z zapisom, in jih kategorizira v tri skupine: T0, T1 in T2. V naslednjem koraku smo uporabili metodo skupnih prostorskih vzorcev (CSP), katere delovanje bo podrobneje opisano v naslednjem poglavju

2.3. Sledi filtriranje pridobljenih signalov z uporabo pasovno-prepustnega filtra med frekvencami 8 in 13 Hz, kar nam omogoča odstranitev neželenih motenj in izboljšanje kakovosti signala. Za zaključek smo izvedli klasifikacijo z uporabo linearne diskriminantne analize (LDA), ki bo prav tako podrobneje opisana v poglavju 2.4. Rezultate našega dela smo nazadnje prikazali grafično, z diagramom raztrosa.

2.1 Povezava na predavanja

Nevron je osnovna celica v možganih, ki za komunikacijo proizvaja električne impulze. Ti impulzi nastanejo zaradi gibanja ionov čez membrane nevronov. Vsak impulz povzroča električno polje, ki je dovolj močno, da ga lahko izmerimo na površini. Takšne izmerjene aktivnosti lahko imenujemo elektroencefalogrami (EEG). Te aktivnosti nam lahko ponazarjajo določena dejanja, kot je stisk roke ali namišljen stisk roke. Za uporabo teh signalov, ki omogočajo komunikacijo med človekom in računalnikom, moramo te signale ustrezno obdelati in klasificirati [3].

2.2 Uporabljeni podatki

Za obdelavo smo izbrali podatke subjekta S001 iz podatkovne baze EEGMMI DS [1], ki je bila objavljena 9. septembra 2009. Ta baza vsebuje EEG posnetke 109 prostovoljcev, ki so izvajali različne motorične naloge in mentalno predstavitev teh nalog. Pri analizi podatkov subjekta S001 smo se osredotočili na 14 eksperimentalnih nalog. Te so vključevale osnovne naloge z odprtimi in zaprtimi očmi ter naloge, kjer je subjekt dejansko izvajal ali si zgolj mentalno predstavljal gibanje pesti ali stopal kot odziv na vizualne signale.

2.3 Skupni prostorski vzorci

Metoda skupnih prostorskih vzorcev (angl. Common Spatial Patterns) je tehnika, ki se pogosto uporablja v analizi možganskih signalov, zlasti pri EEG podatkih. Ta metoda je zasnovana za maksimiranje razlike v razpršenosti signala med dvema stanjema, kot sta aktivnost in počitek, ali, v našem primeru, dejansko gibanje in imaginarno gibanje. Metoda Skupnih prostorskih vzorcev to doseže z izračunom skupnih prostorskih filtrov, ki učinkovito filtrirajo in razdelijo multivariatni signal na sestavne dele. [4]

2.4 Linearna diskriminacija

Linearna diskriminantna analiza (angl. Linear discriminant analysis) je statistična metoda, ki se uporablja za razlikovanje med dvema ali več skupinama na osnovi njunih značilk. V našem projektu smo jo uporabili za klasifikacijo EEG signalov, ki smo jih obdelali z metodo skupnih prostorskih vzorcev in filtrirali z pasovno-prepustnim filtrom. Linearna diskriminantna analiza nam je omogočila, da smo iz značilk EEG signalov ustvarili model, ki prikazuje različne vrste motorične aktivnosti. Linearna diskriminantna analiza deluje tako, da poišče linearno kombinacijo značilk, ki najbolje ločuje med različnimi stanji. [5]

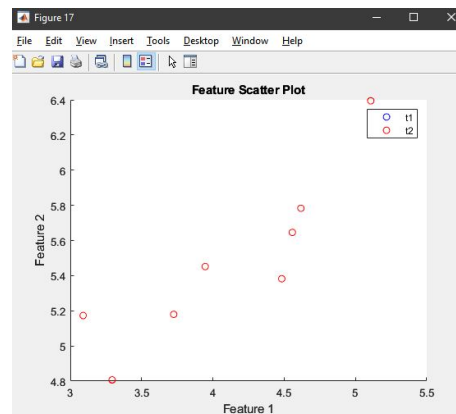
3 Rezultati

Za pridobivanje rezultatov smo uporabili skripto doClassification.m, ki je dostopna na spletni učilnici. Ta skripta nam je olajšala klasifikacijo podatkov, pridobljenih z metodo skupnih prostorskih vzorcev. Kot glavni klasifikator smo izbrali linearno diskriminantno analizo, pri čemer smo podrobneje preučili senзитivnost, specifičnost, klasifikacijsko natančnost in površino pod krivuljo ROC ali s kartico AUC.

Subjekt	Senzitivnost (%)	Specifičnost (%)	Klasifikacijska točnost (%)	AUC (%)
001	38.74	39.64	39.19	34.97

Tabela 1. Rezultati klasifikacije za subjekt 001

Spodnja slika prikazuje diagram raztrosa, ki ilustrira ključne značilnosti našega primera. Ta diagram nam omogoča vizualno analizo odnosov med različnimi klasificiranimi skupinami.



Slika 1. Zaslonska slika diagrama raztrosa značilk.

4 Diskusija

Za podatke subjekta S001 smo pričakovali boljše rezultate, vendar smo dobili manj zadovoljive rezultate. Sklepamo, da je lahko prišlo do napake pri zajemu podatkov ali pri sami klasifikaciji podatkov v kodi. Dobro bi bilo testirati tudi na večjem številu subjektov, na primer S002, S003, S004, da vidim, ali smo dobili podobne rezultate kot za subjekt S001. Nadgradnja naloge bi lahko bila tudi vključitev rezultatov kvadratne diskriminantne analize, ki jo prav tako ponuja skripta doClassification.m ter avtomatično primerjanje med več vrstami subjektov.

Literatura

1. EEG Motor Movement/Imagery Dataset, <https://www.physionet.org/content/eegmdb/1.0.0/>. Dostopano 30.1.2024
2. Waveform Database Software Package (WFDB) for MATLAB and Octave, <https://physionet.org/content/wfdb-matlab/0.10.0/>. Dostopano 30.1.2024
3. Elektroencefalografija, <https://sl.wikipedia.org/wiki/Elektroencefalografija>. Dostopano 30.1.2024
4. Common Spatial Pattern, <https://www.sciencedirect.com/topics/engineering/common-spatial-pattern>. Dostopano 30.1.2024
5. Linear discriminant analysis, https://en.wikipedia.org/wiki/Linear_discriminant_analysis. Dostopano 30.1.2024